

柯蝶旋

求职意向：Agent 工程师（LLM Agent / 智能体应用开发）

27 岁 · 硕士 · 4 年工作经验 · 期望城市：深圳 / 广州 · 可到岗时间：两周内

电话：138-2230-1976

邮箱：kediexuan@outlook.com

GitHub：github.com/kediexuan

个人简介

四年 NLP 与大模型应用研发经验，近两年专注 LLM Agent 方向。主导过面向企业客服与内部知识管理的多智能体系统从 0 到 1 落地，熟悉 ReAct / Plan-and-Execute / 多 Agent 编排范式，具备工具调用协议设计、RAG 检索链路优化、Agent 评测体系搭建与线上稳定性治理的完整经验。习惯以评测数据驱动迭代，重视可观测性与成本控制。

专业技能

Agent 框架	LangGraph、LangChain、AutoGen、OpenAI Agents SDK；熟悉 MCP（Model Context Protocol）与 Function Calling 规范，能自研轻量级 Agent Runtime
大模型	熟练使用 GPT-4o、Claude、DeepSeek、Qwen 系列 API；掌握 Prompt 工程、结构化输出约束、上下文压缩与长任务记忆管理；有 LoRA 微调与 vLLM 部署经验
RAG / 检索	Milvus、Elasticsearch、pgvector；文档切分策略、Hybrid Search、Rerank（bge-reranker）、查询改写与引用溯源
工程能力	Python（主力）、TypeScript；FastAPI、asyncio、Celery、Redis、PostgreSQL；Docker、Kubernetes、GitHub Actions；Langfuse / OpenTelemetry 链路追踪
评测与安全	搭建 Agent 离线评测集与在线 A/B 体系（任务成功率、工具调用准确率、幻觉率）；Prompt 注入防护、工具权限最小化、输出审核
语言	英语 CET-6（578），可流畅阅读英文论文与技术文档

工作经历

深圳云帆智联科技有限公司 大模型应用部 · Agent 工程师 2024.03 - 至今

- 企业客服多 Agent 系统（核心负责人）**：基于 LangGraph 设计「路由 Agent + 领域 Agent + 审核 Agent」架构，覆盖售前咨询、订单查询、售后工单三类场景，接入 CRM / 订单 / 物流等 14 个业务工具。上线后自助解决率由 41% 提升至 68%，人工转接率下降 37%，日均处理会话 2.3 万。
- 工具调用协议与 Runtime**：基于 MCP 规范统一内部工具接入方式，实现工具注册、参数校验、超时重试、结果缓存与权限隔离；工具调用参数错误率由 8.6% 降至 1.9%，新工具接入周期由 3 天缩短至 0.5 天。
- Agent 评测体系**：构建 1,200 条标注任务的离线评测集，设计任务成功率、步骤冗余度、工具选择准确率等指标，并接入 Langfuse 做线上抽样回放；将 Prompt 与模型升级的回归验证时间从人工 2 天压缩至 40 分钟。
- 成本与稳定性治理**：引入模型分级路由（简单意图走 Qwen2.5-7B 自部署，复杂推理走 GPT-4o）、语义缓存与上下文裁剪，单会话平均 Token 成本下降 46%，P95 首字延迟控制在 1.8s 以内。
- 安全防护**：实现 Prompt 注入检测、敏感信息脱敏与高风险操作二次确认机制，通过公司内部红队测试与 ISO 27001 合规审查。

广州启元数据科技有限公司 AI 算法组 · NLP 算法工程师 2022.07 - 2024.02

- 企业知识库问答（RAG）**：负责检索链路设计与优化，实现基于语义与结构的混合切分、BM25 + 向量 Hybrid Search 与 bge-reranker 重排，答案准确率（人工评估）由 62% 提升至 84%，服务 3 家金融行业客户。
- 意图识别与信息抽取**：基于 BERT / RoBERTa 训练多标签意图分类与实体抽取模型，F1 达 0.93；设计弱监督数据增强流程，减少 60% 标注成本。
- 模型服务化**：使用 vLLM 部署 Qwen-14B 并完成 LoRA 领域微调，吞吐提升 3.2 倍；建设统一推理网关，支持灰度发布与多模型 AB 对比。

项目经历

DevPilot: 面向研发团队的代码任务 Agent 开源 · 个人项目 2025.01 – 2025.06

- 实现「需求理解 → 仓库检索 → 计划生成 → 编码执行 → 测试验证」的 Plan-and-Execute Agent, 支持沙箱内执行命令与自动回滚; 在 SWE-bench Lite 子集上通过率 27.5%。
- 设计基于 AST 与嵌入的双路代码检索, 并引入反思 (Reflexion) 机制降低重复失败; GitHub Star 420+, 被 2 个团队用于内部试点。

内部知识助理 Agent (云帆智联) 2024.09 – 2024.12

- 打通 Confluence、飞书文档、Jira 与 GitLab 四类数据源, 实现带权限过滤的检索与多轮澄清; 支持「查进度 → 建任务 → 发通知」的跨系统自动化操作, 覆盖 600+ 员工, 周活 72%。

教育背景

华南理工大学 计算机科学与技术 · 硕士 2019.09 – 2022.06

研究方向: 对话系统与知识增强的自然语言生成; 发表 CCF-C 类会议论文 1 篇 (第一作者), 获硕士研究生学业奖学金。

华南农业大学 软件工程 · 本科 2015.09 – 2019.06

GPA 3.7 / 4.0, ACM-ICPC 亚洲区域赛铜牌, 校优秀毕业生。

其他

- 技术博客累计发表 Agent 相关文章 20 余篇 (LangGraph 状态机设计、MCP 实践、Agent 评测方法论), 全网阅读量 15 万+。
- 持续关注 Agent 协议标准化 (MCP、A2A) 与长程任务记忆研究, 业余时间为 LangGraph 社区提交过 3 个 PR。